



# Detección de Fatiga en Jugadores de Pádel mediante Forecasting de Series Temporales

Alejandro Riveros Sobrino & Juan David Quitian & Simon Burbano & Cesar Diaz

Universidad de La Sabana  
Clase de Analítica de Datos

## Resumen

Se propone un método para detectar y anticipar la fatiga en jugadores de pádel a partir de datos de *tracking* de video. A partir de coordenadas frame a frame se construye un **índice de actividad compuesto** por punto jugado, que combina cinco variables físicas normalizadas por *z-score*: velocidad mediana activa, velocidad pico, aceleración media, desplazamiento total y golpes por punto. Para capturar la evolución a lo largo del torneo se concatenan todos los partidos disponibles, obteniendo series de 9–57 puntos por jugador. Se ajustan tres modelos de forecasting — Suavizamiento Exponencial (Holt), ARIMA y Prophet — y se comparan mediante MAE, RMSE,  $R^2$  y SMAPE. Los resultados muestran tendencias descendentes del índice consistentes con acumulación de fatiga, con ARIMA como modelo de mejor desempeño promedio.

## 1. Introducción

La fatiga en deportes de raqueta reduce la velocidad de reacción, la precisión del golpe y la capacidad de cobertura de cancha. Detectarla antes de que sea crítica permite intervenciones tácticas y físicas oportunas.

**Pregunta central:** ¿El rendimiento físico de un jugador sigue un patrón predecible durante el torneo y puede anticiparse cuándo empieza a decaer?

**Hipótesis:** El índice de actividad del jugador tiende a disminuir a medida que acumula puntos durante el torneo como consecuencia de la fatiga acumulada. Esta caída sostenida puede modelarse y anticiparse con técnicas de forecasting.


### Temas aplicados del módulo:

1. Promedios Móviles y Suavizamiento Exponencial (SMA, EMA)
2. Evaluación de Modelos de Forecasting (MAE, RMSE,  $R^2$ , SMAPE)
3. Suavizamiento de Holt-Winters
4. Modelos ARIMA
5. Prophet (Meta)

**¿Por qué importa en pádel?** Un partido de pádel puede durar entre 60 y 120 minutos con puntos de alta intensidad intercalados. A diferencia de deportes con pausas reglamentarias, la fatiga se acumula de forma continua y el jugador raramente percibe su propia caída de rendimiento. Detectarla con datos objetivos permite tomar decisiones tácticas en tiempo real.

## 2. Metodología

### 2.1. Pipeline de Procesamiento



Los datos provienen del *tracking* de video a 60 fps (velocidad, desplazamiento, aceleración, golpes). **Limpieza:** se eliminaron 20 949 frames (4.8 %) con velocidad irreal ( $>8$  m/s) o nombre de jugador no reconocido. **Agregación:** de 413 249 frames a 882 puntos (reducción 469×), usando la tripleta (partido, punto, jugador) como unidad de análisis.

### 2.2. Índice de Actividad Compuesto

Se agregan los datos frame a frame por partido, punto y jugador. Luego se calcula un índice ponderado de cinco componentes, cada uno normalizado a *z-score* global ( $\mu = 0$ ,  $\sigma = 1$ ):

$$\mathcal{I}_t = \sum_v w_v \cdot z_v, \quad z_v = \frac{x_v - \bar{x}_v}{s_v} \quad (1)$$

| Variable                 | Peso $w_v$ | Aspecto              |
|--------------------------|------------|----------------------|
| Velocidad mediana activa | 0.25       | Esfuerzo sostenido   |
| Velocidad pico           | 0.20       | Capacidad explosiva  |
| Aceleración media        | 0.20       | Potencia de arranque |
| Desplazamiento total     | 0.20       | Carga física total   |
| Golpes por punto         | 0.15       | Actividad técnica    |

$\mathcal{I}_t > 0$ : punto de alta intensidad (jugador fresco).  
 $\mathcal{I}_t < 0$ : punto de baja intensidad (posible fatiga).

2.3. Serie Temporal: punto\_global

Tras la agregación se crea el eje temporal acumulado:

punto\_global\_j = cumcount(jugador\_j) + 1 (2)

que cuenta los puntos jugados por cada jugador a lo largo de todo el torneo, sin importar el partido. Esto permite series de 9–57 observaciones por jugador, suficientes para los modelos de forecasting.

2.4. Modelos de Forecasting

Se divide la serie en 70 % train / 30 % test y se ajustan:

- 1. Naive: predicción constante = último valor de train (línea base).
- 2. Holt (ES): suavizamiento exponencial doble con tendencia aditiva.
- 3. ARIMA: orden (p, d, q) seleccionado automáticamente mediante prueba ADF y correlogramas ACF/PACF.
- 4. Prophet: modelo aditivo de Meta con changepoints, sin estacionalidad (serie muy corta).

2.5. Métricas de Evaluación

| Métrica | Descripción                                                                     |
|---------|---------------------------------------------------------------------------------|
| MAE     | Error absoluto medio. Fácil de interpretar.                                     |
| RMSE    | Raíz del error cuadrático. Penaliza errores grandes. <b>Criterio principal.</b> |
| R²      | Proporción de variabilidad explicada (1 = perfecto).                            |
| SMAPE   | Error porcentual simétrico, robusto ante valores negativos o cercanos a 0.      |

SMAPE se prefiere sobre MAPE porque  $\mathcal{I}_t$  es un z-score que puede ser negativo o próximo a cero:

SMAPE = 100 / n \* sum\_{t=1}^n (2 \* |y\_t - y\_hat\_t| / (|y\_t| + |y\_hat\_t| + epsilon)) (3)

3. Resultados

3.1. Tendencia del Índice de Actividad




Figura: Índice de actividad con SMA 3, EMA 3 y forecast ARIMA para Alejandra Salazar Galeano.

Los promedios móviles (SMA 5, EMA 5) revelan una tendencia descendente del índice a lo largo del punto\_global para 16 de 34 jugadores, consistente con la hipótesis de

fatiga acumulada en ese grupo. Los cruces de medias móviles (Death Cross) se detectaron en el tramo final del torneo, coincidiendo con los puntos de mayor desgaste físico.

3.2. Comparación de Modelos

La tabla siguiente resume el promedio de las métricas sobre todos los jugadores evaluados. Se prioriza RMSE como criterio de selección:

| Modelo                                                | MAE    | RMSE          | R²    | SMAPE   |
|-------------------------------------------------------|--------|---------------|-------|---------|
| ARIMA                                                 | 0.3618 | <b>0.4417</b> | -2.71 | 122.7 % |
| Naive                                                 | 0.3859 | 0.4676        | -3.52 | 111.7 % |
| Prophet                                               | 0.4758 | 0.5599        | -5.50 | 138.5 % |
| Holt (ES)                                             | 0.5029 | 0.5887        | -5.72 | 131.6 % |
| Promedio sobre 34 jugadores. Criterio: menor RMSE.    |        |               |       |         |
| R² negativo: variabilidad alta del z-score; ver nota. |        |               |       |         |

Nota: R² negativo indica que la variabilidad intrínseca del índice de actividad (z-score con alta fluctuación punto a punto) supera la capacidad predictiva de todos los modelos. Es esperado en series cortas de alta varianza. RMSE sigue siendo el criterio de comparación relativa entre modelos.

3.3. Comparación entre Jugadores

Para comparar jugadores se estima una regresión lineal entre el eje temporal y el índice de actividad. Su pendiente cuantifica la tasa de caída del rendimiento a lo largo del torneo completo:

I\_hat\_t = beta\_0 + beta\_1 \* t + epsilon\_t, t = punto\_global (4)

Pendiente beta\_1 < -0,02: caída fuerte (fatiga evidente).  
Pendiente -0,02 <= beta\_1 < 0: caída leve.  
Pendiente beta\_1 >= 0: estable o mejora.

De 34 jugadores evaluados: 8 muestran caída fuerte (beta\_1 < -0,02), 8 caída leve (-0,02 <= beta\_1 < 0) y 18 tendencia estable o de mejora. El jugador con mayor fatiga acumulada fue Alejandra Salazar Galeano (pendiente = -0,087, R² = 0,365); el más estable fue Ángel Santiago Toribio Godoy (pendiente = +0,094, R² = 0,665).

4. Conclusiones

- 1. El índice de actividad compuesto permite capturar la fatiga de forma más robusta que el desplazamiento aislado, al integrar velocidad, aceleración y actividad técnica.
- 2. La concatenación de partidos del torneo permite construir series de 9–57 puntos, lo que dota a ARIMA y Prophet de mayor base estadística para la estimación.
- 3. Se observa caída del índice en 16 de 34 jugadores, mientras 18 muestran tendencia estable o de mejora.
- 4. ARIMA resultó ser el modelo de menor RMSE promedio, con capacidad de capturar la tendencia decreciente de la serie.
- 5. La comparación entre jugadores mediante la pendiente de la tendencia lineal permite identificar quién se fatiga más rápidamente a lo largo del torneo completo.

5. Aplicación Práctica

¿En qué me beneficia este análisis como jugador?

Para el jugador: conocer en qué punto global su índice de actividad empieza a caer le permite identificar cuándo su rendimiento físico es más vulnerable. Por ejemplo, si

su Death Cross aparece siempre entre los puntos 20–25, puede ajustar su estrategia (ritmo, tipo de golpe, posicionamiento) antes de llegar a ese umbral.

**Para el entrenador:** comparar las pendientes de caída entre jugadores permite priorizar el trabajo físico. Los 8 jugadores con caída fuerte ( $\beta_1 < -0,02$ ) se benefician de entrenamientos específicos de resistencia; los 18 estables sirven como referencia de rendimiento sostenido.

**Para la táctica en partido:** el modelo ARIMA (menor RMSE = 0.44) puede proyectar el índice en los próximos puntos. Si la proyección es descendente, el jugador o su pareja pueden asumir más protagonismo en los puntos críticos.

El análisis transforma datos de tracking —que normalmente solo se usan para revisión pospartido— en una herramienta de toma de decisiones **en tiempo real**, cerrando el ciclo entre datos, modelo y acción deportiva.

## Referencias

- Box, G. E. P. & Jenkins, G. M. (1976). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Holt, C. C. (1957). Forecasting seasonals and trends by exponentially weighted moving averages. *ONR Memorandum*, 52.
- Taylor, S. J. & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.
- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.